多元二次函数的极值与 HESSIAN 矩阵的关系

The Relationship between the Extremum of Multivariate Quadratic Function and Hessian Matrix

by **Glenn Chentianye Xu**

Dec 10th, 2021

目　录

一、基本概念的引入……02

二、Hessian 矩阵特征值、特征向量与函数图像关系：从二阶方向导数说起……05

三、Hessian 矩阵、函数凹凸性与函数极值：从优化角度分析……07

四、综合考虑——以二元二次函数为例……09

五、结论汇总……15

参考文献……20

一、基本概念的引入

（一）多元二次函数[1] (Chinese Version, Page 65), [4] (Second Edition, Chinese Version, Page 114)

考虑 n 元函数 $f:\mathbf{R}^n \to \mathbf{R}$，其定义域为 $\mathbf{dom}\, f = \mathbf{R}^n$，其表达式为

$$f(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x} + \boldsymbol{d}^T\boldsymbol{x} + c\,,$$

其中 $\boldsymbol{A}$ 是 $n\times n$ 实对称矩阵，$\boldsymbol{d}\in\mathbf{R}^n$，$c$ 属于 $\mathbf{R}$，则该函数称为 n **元二次函数**。

（二）Hessian 矩阵[2] (Chinese Version, Page165)

实值函数 $f(\boldsymbol{x})$ 相对于 $m\times 1$ 实向量 $\boldsymbol{x}$ 的二阶偏导称为 Hessian **矩阵**，记作 $\boldsymbol{H}[f(\boldsymbol{x})]$，定义为

$$\boldsymbol{H}[f(\boldsymbol{x})] = \frac{\partial^2 f(\boldsymbol{x})}{\partial\boldsymbol{x}\partial\boldsymbol{x}^{\mathrm{T}}} = \frac{\partial}{\partial\boldsymbol{x}}\left[\frac{\partial f(\boldsymbol{x})}{\partial\boldsymbol{x}^{\mathrm{T}}}\right] \in \mathbf{R}^{m\times m}$$

或记作

$$\boldsymbol{H}[f(\boldsymbol{x})] = \nabla_{\boldsymbol{x}}^2 f(\boldsymbol{x}) = \nabla_{\boldsymbol{x}}(\mathrm{D}_{\boldsymbol{x}} f(\boldsymbol{x}))$$

式中 $\mathrm{D}_{\boldsymbol{x}}$ 为协梯度算子。于是，Hessian 矩阵的第 (i, j) 元素定义为

$$\left[\boldsymbol{H}f(\boldsymbol{x})\right]_{i,j} = \left[\frac{\partial^2 f(\boldsymbol{x})}{\partial\boldsymbol{x}\partial\boldsymbol{x}^{\mathrm{T}}}\right]_{i,j} = \frac{\partial}{\partial x_i}\left[\frac{\partial f(\boldsymbol{x})}{\partial x_j}\right]$$

或写作

$$\boldsymbol{H}[f(\boldsymbol{x})] = \frac{\partial^2 f(\boldsymbol{x})}{\partial\boldsymbol{x}\partial\boldsymbol{x}^{\mathrm{T}}} = \begin{bmatrix} \dfrac{\partial^2 f}{\partial x_1\partial x_1} & \cdots & \dfrac{\partial^2 f}{\partial x_1\partial x_m} \\ \vdots & \ddots & \vdots \\ \dfrac{\partial^2 f}{\partial x_m\partial x_1} & \cdots & \dfrac{\partial^2 f}{\partial x_m\partial x_m} \end{bmatrix} \in \mathbf{R}^{m\times m}$$

即实标量函数 $f(\boldsymbol{x})$ 的 Hessian 矩阵是一个 $m\times m$ 的正方矩阵，由标量函数 $f(\boldsymbol{x})$ 关于向量变元 $\boldsymbol{x}$ 的元素 x_i 的 m^2 个二阶偏导组成。

由定义式知，实标量函数 $f(\boldsymbol{x})$ 的 Hessian 矩阵是一个实对称矩阵

$$\left(\boldsymbol{H}[f(\boldsymbol{x})]\right)^{\mathrm{T}} = \boldsymbol{H}[f(\boldsymbol{x})]$$

因为二次可导连续函数 $f(\boldsymbol{x})$ 的二次求导与求导顺序无关，即 $\dfrac{\partial^2 f}{\partial x_i\partial x_j} = \dfrac{\partial^2 f}{\partial x_j\partial x_i}$。

（三）多元二次函数的 Hessian 矩阵与泰勒展开

根据以上定义，我们可以求出一般的 n 元二次函数的 Hessian 矩阵。

对于（一）中定义的 n 元二次函数，首先求其梯度。根据 The Matrix Cookbook 2012 版[3] (Page 10)第 10 页式 69 和式 81，我们有 $\frac{\partial \boldsymbol{x}^T\boldsymbol{a}}{\partial \boldsymbol{x}}=\frac{\partial \boldsymbol{a}^T\boldsymbol{x}}{\partial \boldsymbol{x}}=\boldsymbol{a}$ 以及 $\frac{\partial \boldsymbol{x}^T\mathbf{B}\boldsymbol{x}}{\partial \boldsymbol{x}}=(\mathbf{B}+\mathbf{B}^T)\boldsymbol{x}$。

又由定义有 $\boldsymbol{A}$ 是 $n\times n$ 实对称矩阵，即 $\boldsymbol{A}=\boldsymbol{A}^T$，则（一）中二次函数的梯度为

$$\nabla f(\boldsymbol{x})=\frac{1}{2}\left(\boldsymbol{A}+\boldsymbol{A}^T\right)\boldsymbol{x}+\boldsymbol{d}=\boldsymbol{A}\boldsymbol{x}+\boldsymbol{d}$$

进而可以计算出其 Hessian 矩阵为

$$\nabla^2 f(\boldsymbol{x})=\boldsymbol{A}$$

容易发现，对于该二次函数而言，更高阶的导数均为 0，即

$$\nabla^k f(\boldsymbol{x})=0, k>2$$

因此对于 n 元二次函数，其在点 $\boldsymbol{x}^*$ 处的泰勒展开为

$$f(\boldsymbol{x})=f(\boldsymbol{x}^*)+\nabla f(\boldsymbol{x})^T\Big|_{\boldsymbol{x}=\boldsymbol{x}^*}(\boldsymbol{x}-\boldsymbol{x}^*)+\frac{1}{2}(\boldsymbol{x}-\boldsymbol{x}^*)^T\nabla^2 f(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*}(\boldsymbol{x}-\boldsymbol{x}^*)$$

（四）方向导数[4] (Second Edition, Chinese Version, Page 110), [5] (Chapter 1, Page 48)

对于多元函数 $f(\boldsymbol{x})$，设向量 $\boldsymbol{p}$ 是想要计算导数的方向上的一个向量，则这个方向导数（斜率）可以由下式求出：

$$\frac{\boldsymbol{p}^T\nabla f(\boldsymbol{x})}{\|\boldsymbol{p}\|}$$

沿方向 $\boldsymbol{p}$ 的二阶梯度（曲率）可以由下式计算：

$$\frac{\boldsymbol{p}^T\nabla^2 f(\boldsymbol{x})\boldsymbol{p}}{\|\boldsymbol{p}\|^2}$$

（五）极小点[4] (Second Edition, Chinese Version, Page 111) , [5] (Chapter 1, Page 56)

强极小点 给定函数 $F(\boldsymbol{x})$ 和点 $\boldsymbol{x}^*$，如果存在一个标量 $\delta>0$，使得对于所有满足 $\delta>\|\Delta\boldsymbol{x}\|>0$ 的 $\Delta\boldsymbol{x}$ 都有 $F(\boldsymbol{x}^*)<F(\boldsymbol{x}^*+\Delta\boldsymbol{x})$，则 $\boldsymbol{x}^*$ 是 $F(\boldsymbol{x})$ 的一个强极小点。

全局极小点 给定函数 $F(\boldsymbol{x})$ 和点 $\boldsymbol{x}^*$，如果对于所有的 $\Delta\boldsymbol{x}$，都有 $F(\boldsymbol{x}^*)<F(\boldsymbol{x}^*+\Delta\boldsymbol{x})$，则 $\boldsymbol{x}^*$ 是 $F(\boldsymbol{x})$ 的唯一全局极小点。

弱极小点 如果 $\boldsymbol{x}^*$ 不是函数 $F(\boldsymbol{x})$ 的强极小点，并且存在一个标量 $\delta > 0$，使得对于所有满足 $\delta > \|\Delta\boldsymbol{x}\| > 0$ 的 $\Delta\boldsymbol{x}$ 都有 $F(\boldsymbol{x}^*) \le F(\boldsymbol{x}^* + \Delta\boldsymbol{x})$，则 $\boldsymbol{x}^*$ 是 $F(\boldsymbol{x})$ 的一个弱极小点。

（六）正定、负定、半正定、半负定与不定[6] (Fifth Edition, Page 423)

【定义】

对于一个二次型 $Q(\boldsymbol{x}) = \boldsymbol{x}^T \boldsymbol{A}\boldsymbol{x}$，其中 $\boldsymbol{A}$ 是一个 $n \times n$ 实对称矩阵，它是：

正定的，当对于所有 $\boldsymbol{x} \ne 0$ 有 $Q(\boldsymbol{x}) > 0$；

半正定的，当对于所有 $\boldsymbol{x} \ne 0$ 有 $Q(\boldsymbol{x}) \ge 0$；

负定的，当对于所有 $\boldsymbol{x} \ne 0$ 有 $Q(\boldsymbol{x}) < 0$；

半负定的，当对于所有 $\boldsymbol{x} \ne 0$ 有 $Q(\boldsymbol{x}) \le 0$；

不定的，当对于任意 $\boldsymbol{x} \ne 0$，$Q(\boldsymbol{x})$ 可能取正也可能取负。

【定理】

若 $\boldsymbol{A}$ 是一个 $n \times n$ 实对称矩阵：

$\boldsymbol{A}$ 是正定的，当且仅当其所有特征值为正；

$\boldsymbol{A}$ 是半正定的，当且仅当其所有特征值非负；

$\boldsymbol{A}$ 是负定的，当且仅当其所有特征值为负；

$\boldsymbol{A}$ 是半负定的，当且仅当其所有特征值非正；

$\boldsymbol{A}$ 是不定的，当且仅当其特征值有正有负。

注：本文后述半正（负）定矩阵是严格半正（负）定矩阵，即不属于正（负）定矩阵。

（七）驻点[5] (Chapter 1, Page 57)

驻点（Stationary Points or Critical Points）是所有一阶偏导数都为零或一阶偏导数不存在的点。

对于多元二次函数，其处处连续、处处可微，因此驻点是所有一阶偏导数为零的点。

（八）多元二次函数的凹凸性与 Hessian 矩阵关系[1] (Chinese Version, Page 65)

对于多元二次函数 $f(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^T \boldsymbol{A}\boldsymbol{x} + \boldsymbol{d}^T \boldsymbol{x} + c$，若 $\boldsymbol{A}$ 是半正定矩阵，则其为凸函数；若 $\boldsymbol{A}$ 是半负定矩阵，则其为凹函数。

二、Hessian 矩阵特征值、特征向量与函数图像关系：从二阶方向导数说起

不妨考察原点为驻点且在该点函数值为 0 的二次函数

$$f(\boldsymbol{x})=\frac{1}{2}\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}$$

因为由定义，$\boldsymbol{A}$ 是实对称矩阵，假设 $\boldsymbol{x}_1$ 和 $\boldsymbol{x}_2$ 是对称矩阵 $\boldsymbol{A}$ 的任意两个特征向量，且 $\boldsymbol{A}\boldsymbol{x}_1=\lambda_1\boldsymbol{x}_1$，$\boldsymbol{A}\boldsymbol{x}_2=\lambda_2\boldsymbol{x}_2$，$\lambda_1\neq\lambda_2$。容易得到 $\boldsymbol{x}_1^T\boldsymbol{A}\boldsymbol{x}_2$ 是一个标量，则

$$\boldsymbol{x}_1^T\boldsymbol{A}\boldsymbol{x}_2=\left(\boldsymbol{x}_1^T\boldsymbol{A}\boldsymbol{x}_2\right)^T=\boldsymbol{x}_2^T\boldsymbol{A}^T\boldsymbol{x}_1=\boldsymbol{x}_2^T\boldsymbol{A}\boldsymbol{x}_1,$$

其中 $\boldsymbol{x}_1^T\boldsymbol{A}\boldsymbol{x}_2=\lambda_2\boldsymbol{x}_1^T\boldsymbol{x}_2$，$\boldsymbol{x}_2^T\boldsymbol{A}\boldsymbol{x}_1=\lambda_1\boldsymbol{x}_2^T\boldsymbol{x}_1=\lambda_1\boldsymbol{x}_1^T\boldsymbol{x}_2$，则有

$$\lambda_1\boldsymbol{x}_1^T\boldsymbol{x}_2=\lambda_2\boldsymbol{x}_1^T\boldsymbol{x}_2$$

即

$$(\lambda_1-\lambda_2)\boldsymbol{x}_1^T\boldsymbol{x}_2=0$$

又有 $\lambda_1\neq\lambda_2$，即 $\lambda_1-\lambda_2\neq0$，因此

$$\boldsymbol{x}_1^T\boldsymbol{x}_2=0$$

即对称矩阵 $\boldsymbol{A}$ 的任意两个特征向量正交。

不妨就将对称矩阵 $\boldsymbol{A}$ 的特征向量作为新的基向量，根据上学期所学内容，以其特征向量作为列向量构成如下矩阵

$$\boldsymbol{B}=\begin{bmatrix}\boldsymbol{z}_1 & \boldsymbol{z}_2 & \cdots & \boldsymbol{z}_n\end{bmatrix}$$

不妨假设这些特征向量都是被标准化的，则该矩阵的逆等于其转置。

下面利用上学期所学内容进行换基，将这些特征向量作为新的基，则有新的 $\boldsymbol{A}$ 为

$$\boldsymbol{A}'=\left[\boldsymbol{B}^T\boldsymbol{A}\boldsymbol{B}\right]=\begin{bmatrix}\lambda_1 & 0 & \cdots & 0\\ 0 & \lambda_2 & \cdots & 0\\ \vdots & \vdots & & \vdots\\ 0 & 0 & \cdots & \lambda_n\end{bmatrix}=\boldsymbol{\Lambda}$$

其中 λ_i 是 $\boldsymbol{A}$ 的特征值。

下面就可以借助二阶方向导数来解释对称矩阵 $\boldsymbol{A}$ 的特征值和特征向量的物理意义以及它们如何决定二次函数曲面形状。

上学期已经学过，函数 $f(\boldsymbol{x})$ 在向量 $\boldsymbol{p}$ 方向上的二阶导数由下式给出

$$\frac{\boldsymbol{p}^T \nabla^2 f(\boldsymbol{x}) \boldsymbol{p}}{\|\boldsymbol{p}\|^2}$$

对于二次函数来说，亦即

$$\frac{\boldsymbol{p}^T \boldsymbol{A} \boldsymbol{p}}{\|\boldsymbol{p}\|^2}$$

不妨定义 $\boldsymbol{p} = \boldsymbol{B}\boldsymbol{c}$， $\boldsymbol{c}$ 为向量 $\boldsymbol{p}$ 在对称矩阵 $\boldsymbol{A}$ 的特征向量为基的空间中的表示，于是上式可以改写为

$$\frac{\boldsymbol{p}^T \boldsymbol{A} \boldsymbol{p}}{\|\boldsymbol{p}\|^2} = \frac{\boldsymbol{c}^T \boldsymbol{B}^T (\boldsymbol{B}\boldsymbol{\Lambda}\boldsymbol{B}^T) \boldsymbol{B}\boldsymbol{c}}{\boldsymbol{c}^T \boldsymbol{B}^T \boldsymbol{B}\boldsymbol{c}} = \frac{\boldsymbol{c}^T \boldsymbol{\Lambda} \boldsymbol{c}}{\boldsymbol{c}^T \boldsymbol{c}} = \frac{\sum_{i=1}^{n} \lambda_i c_i^{\,2}}{\sum_{i=1}^{n} c_i^{\,2}}$$

记 $\theta_k = \dfrac{c_k^{\,2}}{\sum_{i=1}^{n} c_i^{\,2}}$， 显然 $\sum_{i=1}^{n} \theta_i = 1$，则上式改写为

$$\frac{\boldsymbol{p}^T \boldsymbol{A} \boldsymbol{p}}{\|\boldsymbol{p}\|^2} = \sum_{i=1}^{n} \lambda_i \theta_i$$

显然上式是对称矩阵 $\boldsymbol{A}$ 的特征值的加权平均，因此有

$$\lambda_{\min} \sum_{i=1}^{n} \theta_i \le \sum_{i=1}^{n} \lambda_i \theta_i \le \lambda_{\max} \sum_{i=1}^{n} \theta_i$$

亦即

$$\lambda_{\min} \le \frac{\boldsymbol{p}^T \boldsymbol{A} \boldsymbol{p}}{\|\boldsymbol{p}\|^2} \le \lambda_{\max}$$

当 $\boldsymbol{p}$ 为任一特征向量 $\boldsymbol{z}_i$ 时，有

$$\boldsymbol{c} = \boldsymbol{B}^T \boldsymbol{p} = \boldsymbol{B}^T \boldsymbol{z}_i = \begin{bmatrix} \boldsymbol{z}_1 & \boldsymbol{z}_2 & \cdots & \boldsymbol{z}_n \end{bmatrix}^T \boldsymbol{z}_i = \begin{bmatrix} 0 & 0 & \cdots & 0 & \underset{\uparrow}{1} & 0 & \cdots & 0 \end{bmatrix}^T$$

第 i 个分量

由此，我们容易得到 $\boldsymbol{p} = \boldsymbol{z}_{\max}$ 时 $\dfrac{\boldsymbol{p}^T \boldsymbol{A} \boldsymbol{p}}{\|\boldsymbol{p}\|^2} = \lambda_{\max}$； $\boldsymbol{p} = \boldsymbol{z}_{\min}$ 时 $\dfrac{\boldsymbol{p}^T \boldsymbol{A} \boldsymbol{p}}{\|\boldsymbol{p}\|^2} = \lambda_{\min}$。

也就是说，特征向量定义了一个新的二次交叉项衰减的坐标系。特征向量被称为函数等高线的主轴。若特征向量对应的特征值绝对值越大，则说明该方向上函数曲率越大，等高线越密集；相反，若特征向量对应的特征值绝对值越小，则说明该方向上函数曲率越小，等高线越稀疏。

由此即可判断函数图像形状。

三、Hessian 矩阵、函数凹凸性与函数极值：从优化角度分析

下面不妨考察多元二次函数的极值与最值。

由多变量微积分我们不难得知，要找到多元函数的极值点，首先要找到所有的驻点。因为显然多元二次函数是连续可微的，因此只要使得其梯度等于 **0** 即可[4] (Second Edition, Chinese Version, Page 113)。

假设二次函数驻点为 $\boldsymbol{x}^*$，我们将一（三）中的多元二次函数的泰勒展开式改写为

$$f(\boldsymbol{x}) = f(\boldsymbol{x}^* + \Delta\boldsymbol{x}) = f(\boldsymbol{x}^*) + \nabla f(\boldsymbol{x})^T\Big|_{\boldsymbol{x}=\boldsymbol{x}^*}\Delta\boldsymbol{x} + \frac{1}{2}\Delta\boldsymbol{x}^T\nabla^2 f(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*}\Delta\boldsymbol{x}$$

其中 $\Delta\boldsymbol{x} = \boldsymbol{x} - \boldsymbol{x}^*$。

在二次函数中，所有的驻点处的梯度等于 **0**，于是有

$$f(\boldsymbol{x}) = f(\boldsymbol{x}^*) + \frac{1}{2}\Delta\boldsymbol{x}^T\nabla^2 f(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*}\Delta\boldsymbol{x}$$

其中 $\Delta\boldsymbol{x} = \boldsymbol{x} - \boldsymbol{x}^*$。

根据微积分思想，我们考虑驻点 $\boldsymbol{x}^*$ 的较小邻域内的点。

若要使该驻点为强极小点，只需在该邻域内，除该点外的所有点的函数值都比它的函数值大，于是有 $\Delta\boldsymbol{x}^T\nabla^2 f(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*}\Delta\boldsymbol{x} > 0$。要使得此式对任意 $\Delta\boldsymbol{x} \neq 0$ 成立，根据线性代数，即要求 $\nabla^2 f(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*}$ 是正定矩阵，即 Hessian 矩阵是正定矩阵。

同样的，若要使该驻点为弱极小点，只需在该邻域内，除该点外的所有点的函数值都大于等于它的函数值，于是有 $\Delta\boldsymbol{x}^T\nabla^2 f(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*}\Delta\boldsymbol{x} \geq 0$。要使得此式对任意 $\Delta\boldsymbol{x} \neq 0$ 成立，根据线性代数，即要求 $\nabla^2 f(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*}$ 是半正定矩阵，即 Hessian 矩阵是半正定矩阵。

同样的，若要使该驻点为强极大点，只需在该邻域内，除该点外的所有点的函数值都比它的函数值小，于是有 $\Delta\boldsymbol{x}^T\nabla^2 f(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*}\Delta\boldsymbol{x} < 0$。要使得此式对任意 $\Delta\boldsymbol{x} \neq 0$ 成立，根据线性代数，即要求 $\nabla^2 f(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*}$ 是负定矩阵，即 Hessian 矩阵是负定矩阵。

同样的，若要使该驻点为弱极大点，只需在该邻域内，除该点外的所有点的函数值都小于等于它的函数值，于是有 $\Delta\boldsymbol{x}^T\nabla^2 f(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*}\Delta\boldsymbol{x} \leq 0$。要使得此式对任意 $\Delta\boldsymbol{x} \neq 0$ 成立，根据线性代数，即要求 $\nabla^2 f(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*}$ 是半负定矩阵，即 Hessian 矩阵是半负定矩阵。

上述结论除了对多元二次函数成立，对于所有多元函数均成立。对于多元函数而言，这是一个充分条件，不是必要条件，因为当泰勒级数的二阶项为 0，而三阶项为正时，一个极小点仍然是强极小点。

但是，对于多元二次函数而言，其泰勒展开没有三阶及三阶以上的项，展开到二阶项已能精确表示原函数，因此上述结论对于多元二次函数来说是充要条件，亦即：

当二次函数 $f(\boldsymbol{x})=\frac{1}{2}\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}+\boldsymbol{d}^T\boldsymbol{x}+c$ 有驻点 $\boldsymbol{x}^*$ 时，则有以下关系：

驻点 $\boldsymbol{x}^*$ 是强极小点，当且仅当 $\boldsymbol{A}$ 是正定矩阵；

驻点 $\boldsymbol{x}^*$ 是弱极小点，当且仅当 $\boldsymbol{A}$ 是半正定矩阵；

驻点 $\boldsymbol{x}^*$ 是强极大点，当且仅当 $\boldsymbol{A}$ 是负定矩阵；

驻点 $\boldsymbol{x}^*$ 是弱极大点，当且仅当 $\boldsymbol{A}$ 是半负定矩阵。

同时，由线性代数知识有正定矩阵和负定矩阵必然可逆，而半正定矩阵和半负定矩阵不可逆。再次观察二次函数的梯度 $\nabla f(\boldsymbol{x})=\boldsymbol{A}\boldsymbol{x}+\boldsymbol{d}$，设 $\nabla f(\boldsymbol{x})=\boldsymbol{A}\boldsymbol{x}+\boldsymbol{d}=\boldsymbol{0}$，当 $\boldsymbol{A}$ 是正定矩阵或负定矩阵时，$\boldsymbol{A}$ 可逆，则可以解出唯一一个驻点 $\boldsymbol{x}^*=-\boldsymbol{A}^{-1}\boldsymbol{d}$，也就是说此时极小（大）值唯一，又因为当 Hessian 矩阵半正（负）定时二次函数是凸（凹）函数，凸（凹）函数任一极值点都是最小（大）值点，因此此时极小（大）值也是最小（大）值。

而当 $\boldsymbol{A}$ 是半正定矩阵或半负定矩阵时，$\boldsymbol{A}$ 不可逆，若其为 $m\times m$ 的方阵，则说明其秩小于 m，对应的方程组要么无解（出现矛盾方程）要么有无数解（欠定方程组），在该问题下，若存在驻点 $\boldsymbol{x}'$，则有 $\boldsymbol{A}\boldsymbol{x}'=-\boldsymbol{d}$，于是有

$$f(\boldsymbol{x}')=\frac{1}{2}\boldsymbol{x}'^T\boldsymbol{A}\boldsymbol{x}'+\boldsymbol{d}^T\boldsymbol{x}'+c=\frac{1}{2}\boldsymbol{x}'^T(-\boldsymbol{d})+\boldsymbol{d}^T\boldsymbol{x}'+c=\frac{1}{2}\boldsymbol{d}^T\boldsymbol{x}'+c$$

也就是说，驻点一定在 $g(\boldsymbol{x})=\frac{1}{2}\boldsymbol{d}^T\boldsymbol{x}+c$ 上。

又由上可知驻点要么没有，要么有无数个。

当有无数个驻点时，由上面得到的结论“驻点 $\boldsymbol{x}^*$ 是弱极小（大）点，当且仅当 $\boldsymbol{A}$ 是半正（负）定矩阵”，同时由最优化理论可得，当 Hessian 矩阵半正（负）定时二次函数是凸（凹）函数，凸（凹）函数任一极值点都是最小（大）值点。则任意两个极值点为 $\boldsymbol{x}_1$ 和 $\boldsymbol{x}_2$ 对应函数值相等（要么同为最大值，要么同为最小值），代入超平面方程不难得到，$\frac{1}{2}\boldsymbol{d}^T\boldsymbol{x}_1+c=\frac{1}{2}\boldsymbol{d}^T\boldsymbol{x}_2+c$，即 $\boldsymbol{d}^T(\boldsymbol{x}_1-\boldsymbol{x}_2)=0$。

当 $\boldsymbol{d}\neq\boldsymbol{0}$ 时，显然所有的驻点共一个超平面 $\boldsymbol{d}^T\boldsymbol{x}=m$（$m$ 为常数）。将其代入与二次函数可得 $f(\boldsymbol{x}')=\frac{1}{2}m+c$。二元二次函数情况下，这些驻点（也是极值点、最值点）在一条平行于 xOy 平面的直线上。

当 $\boldsymbol{d}=\boldsymbol{0}$ 时，始终有 $\boldsymbol{d}^T\boldsymbol{x}=0$。将其代入与二次函数可得 $f(\boldsymbol{x}')=c$。

因此综上，当 $\boldsymbol{A}$ 是正定矩阵或负定矩阵时，存在唯一极小（大）值点 $\boldsymbol{x}^* = -\boldsymbol{A}^{-1}\boldsymbol{d}$，同时也是最小（大）值点；

当 $\boldsymbol{A}$ 是半正定矩阵或半负定矩阵时，要么没有极值点（对应方程组 $\nabla f(\boldsymbol{x}) = \boldsymbol{0}$ 出现矛盾方程），要么有无数个极值点（对应方程组 $\nabla f(\boldsymbol{x}) = \boldsymbol{0}$ 欠定），且它们都是最值点。

四、综合考虑——以二元二次函数为例

注：下面的函数图像使用 GeoGebra 绘制，参见附件`曲面的等高线绘制.ggb`。

下面我们综合第二、三两部分的讨论，以二元二次函数为例，讨论函数曲线的形状。

（一）Hessian 矩阵的特征值都为正时（Hessian 矩阵正定）

当 Hessian 矩阵的特征值都为正时，由线性代数知识可知此时 Hessian 矩阵正定，由上面两部分分析可知，此时存在唯一强极小值点，同时也是最小值点。

【例一】（特征值相等时） $f(\boldsymbol{x}) = x_1^2 + x_2^2 = \frac{1}{2}\boldsymbol{x}^T \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \boldsymbol{x}$.

Hessian 矩阵以及它的特征值、特征向量为：

$$\nabla^2 f(\boldsymbol{x}) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix},\quad \lambda_1 = 2,\quad \boldsymbol{z}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix},\quad \lambda_2 = 2,\quad \boldsymbol{z}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

由于所有特征值都相等，所有方向上的曲率也相同，因此该函数的等高线是一系列同心圆，函数曲面形状是一个圆形空洞（如下图 1、图 2 所示）。

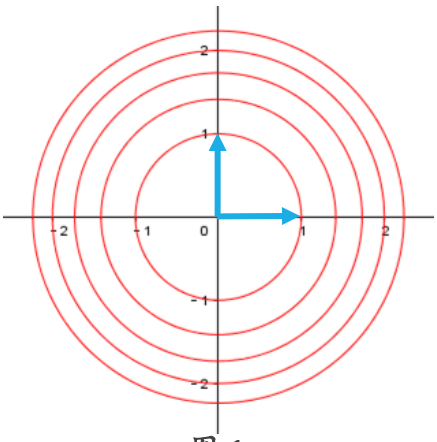

图 1

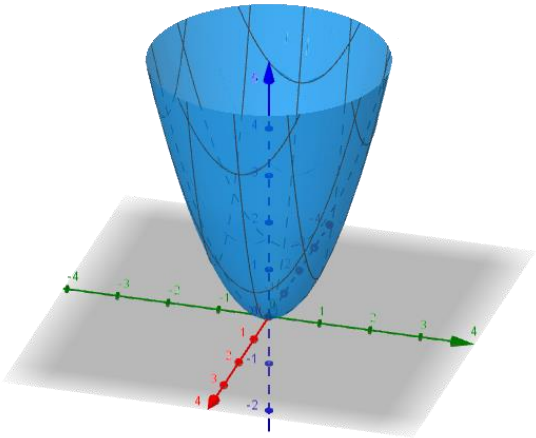

图 2

【例二】（特征值不相等时） $f(\boldsymbol{x})=x_1^2+x_1x_2+x_2^2=\frac{1}{2}\boldsymbol{x}^T\begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix}\boldsymbol{x}$.

Hessian 矩阵以及它的特征值、特征向量为：

$$\nabla^2 f(\boldsymbol{x})=\begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix},\quad \lambda_1=1,\quad \boldsymbol{z}_1=\begin{bmatrix}1\\ -1\end{bmatrix},\quad \lambda_2=3,\quad \boldsymbol{z}_2=\begin{bmatrix}1\\ 1\end{bmatrix}$$

在这种情况下，最大曲率落在 $\boldsymbol{z}_2$ 的方向上，该方向上的等高线更加稠密。因此该函数的等高线是一系列同中心椭圆，函数曲面形状是一个椭圆空洞（如下图 3、图 4 所示）。

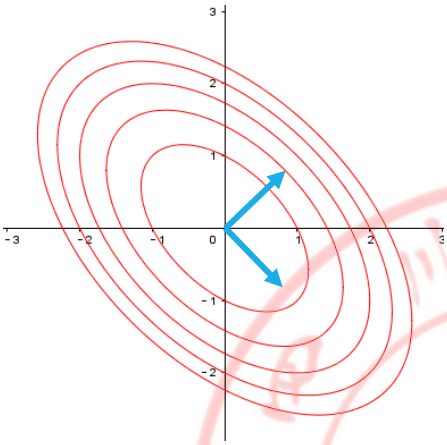

图 3

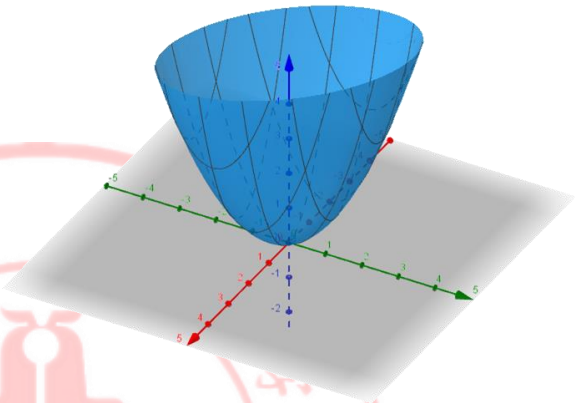

图 4

（二）Hessian 矩阵的特征值都为负时（Hessian 矩阵负定）

当 Hessian 矩阵的特征值都为负时，由线性代数知识可知此时 Hessian 矩阵负定，由上面两部分分析可知，此时存在唯一强极大值点，同时也是最大值点。

【例三】（特征值相等时） $f(\boldsymbol{x})=-x_1^2-x_2^2=\frac{1}{2}\boldsymbol{x}^T\begin{bmatrix}-2 & 0\\ 0 & -2\end{bmatrix}\boldsymbol{x}$.

Hessian 矩阵以及它的特征值、特征向量为：

$$\nabla^2 f(\boldsymbol{x})=\begin{bmatrix}-2 & 0\\ 0 & -2\end{bmatrix},\quad \lambda_1=-2,\quad \boldsymbol{z}_1=\begin{bmatrix}1\\ 0\end{bmatrix},\quad \lambda_2=-2,\quad \boldsymbol{z}_2=\begin{bmatrix}0\\ 1\end{bmatrix}$$

由于所有特征值都相等，所有方向上的曲率也相同，因此该函数的等高线是一系列同心圆，函数曲面形状是一个倒圆形空洞（如下图 5、图 6 所示）

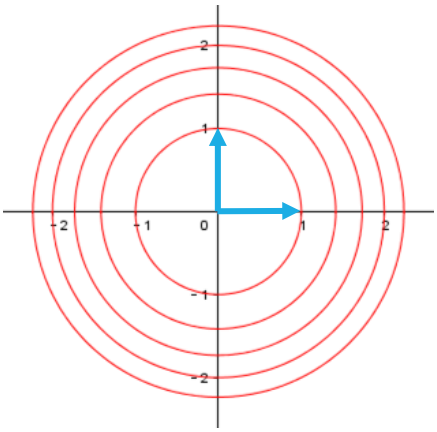

图 5

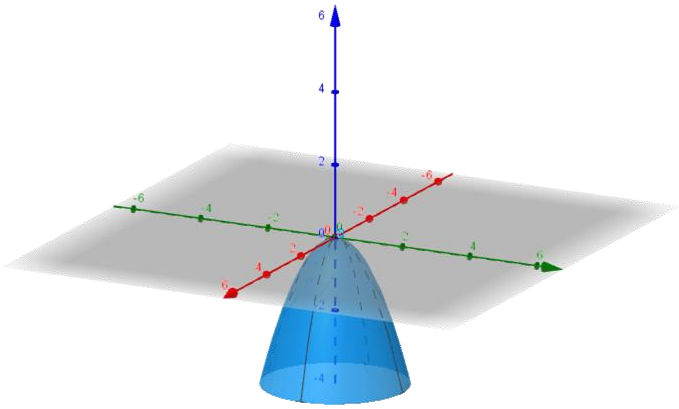

图 6

【例四】（特征值不相等时） $f(\boldsymbol{x})=-x_1^2-x_1x_2-x_2^2=\frac{1}{2}\boldsymbol{x}^T\begin{bmatrix}-2 & -1\\ -1 & -2\end{bmatrix}\boldsymbol{x}$.

Hessian 矩阵以及它的特征值、特征向量为：

$$\nabla^2 f(\boldsymbol{x})=\begin{bmatrix}-2 & -1\\ -1 & -2\end{bmatrix},\ \lambda_1=-1,\ \boldsymbol{z}_1=\begin{bmatrix}1\\ -1\end{bmatrix},\ \lambda_2=-3,\ \boldsymbol{z}_2=\begin{bmatrix}1\\ 1\end{bmatrix}$$

在这种情况下，绝对值最大的曲率落在 $\boldsymbol{z}_2$ 的方向上，该方向上的等高线更加稠密。因此该函数的等高线是一系列同中心椭圆，函数曲面形状是一个倒椭圆空洞（如下图 7、图 8 所示）。

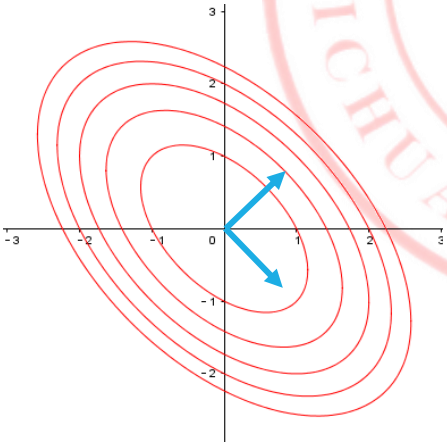

图 7

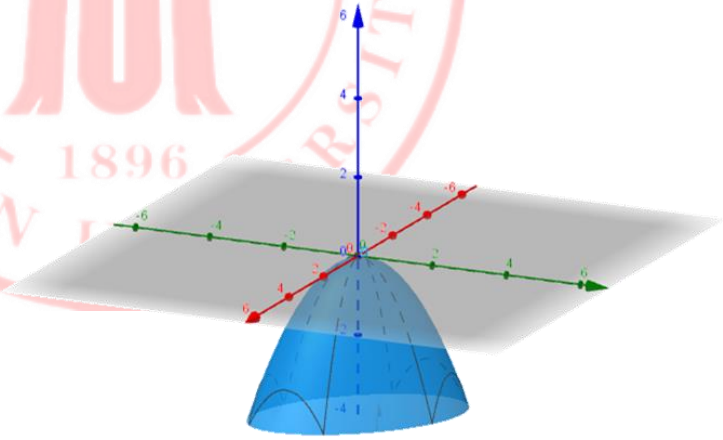

图 8

（三）Hessian 矩阵的特征值一正一零时（Hessian 矩阵半正定）

当 Hessian 矩阵的特征值一正一零时，由线性代数知识可知此时 Hessian 矩阵半正定，由上面两部分分析可知，此时要么没有极值点，要么有无数个共线的极值点。

【例五】（$\nabla f(\boldsymbol{x})=\boldsymbol{0}$ 欠定时） $f(\boldsymbol{x})=\frac{1}{2}x_1^2-x_1x_2+\frac{1}{2}x_2^2=\frac{1}{2}\boldsymbol{x}^T\begin{bmatrix}1 & -1\\ -1 & 1\end{bmatrix}\boldsymbol{x}$.

Hessian 矩阵以及它的特征值、特征向量为：

$$\nabla^2 f(\boldsymbol{x})=\begin{bmatrix}1 & -1\\ -1 & 1\end{bmatrix},\quad \lambda_1=2,\quad \boldsymbol{z}_1=\begin{bmatrix}-1\\ 1\end{bmatrix},\quad \lambda_2=0,\quad \boldsymbol{z}_2=\begin{bmatrix}-1\\ -1\end{bmatrix}$$

在这种情况下，第二个特征值是 0，也就是说在 $\boldsymbol{z}_2$ 方向上曲率为 0，由第三部分的分析可知，所有的极值点（此时也是最小值点）在一条直线上。该函数的等高线是一系列平行直线，函数曲面形状是一个驻点凹槽（平稳谷）（如下图 9、图 10 所示）。

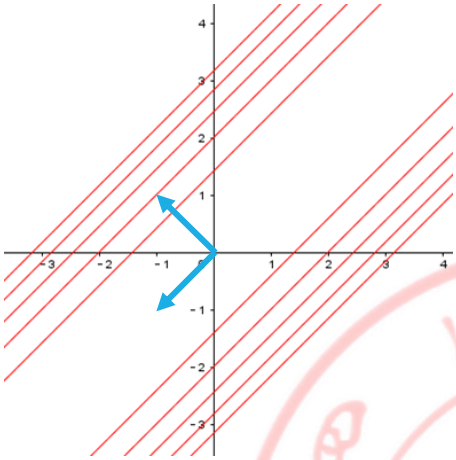

图 9

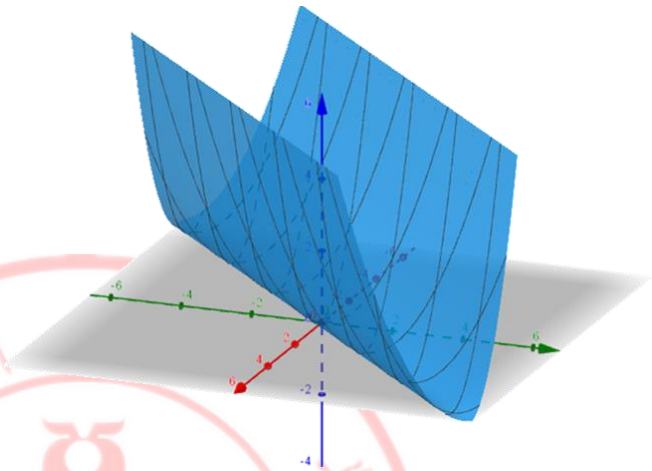

图 10

【例六】（$\nabla f(\boldsymbol{x})=\boldsymbol{0}$ 出现矛盾方程无解时）

$$f(\boldsymbol{x})=\frac{1}{2}x_1^2-x_1x_2+\frac{1}{2}x_2^2+x_2=\frac{1}{2}\boldsymbol{x}^T\begin{bmatrix}1 & -1\\ -1 & 1\end{bmatrix}\boldsymbol{x}+\begin{bmatrix}0\\ 1\end{bmatrix}^T\boldsymbol{x}.$$

Hessian 矩阵以及它的特征值、特征向量为：

$$\nabla^2 f(\boldsymbol{x})=\begin{bmatrix}1 & -1\\ -1 & 1\end{bmatrix},\quad \lambda_1=2,\quad \boldsymbol{z}_1=\begin{bmatrix}-1\\ 1\end{bmatrix},\quad \lambda_2=0,\quad \boldsymbol{z}_2=\begin{bmatrix}-1\\ -1\end{bmatrix}$$

在这种情况下，令 $\nabla f(\boldsymbol{x})=\boldsymbol{0}$，则对应方程组 $\begin{cases}x-y=0\\ -x+y=-1\end{cases}$，两式矛盾，无解，亦即不存在驻点。该函数的等高线是一系列芽形线，函数曲面形状是一个山谷（倾斜凹槽）（如下图 11、图 12 所示）。

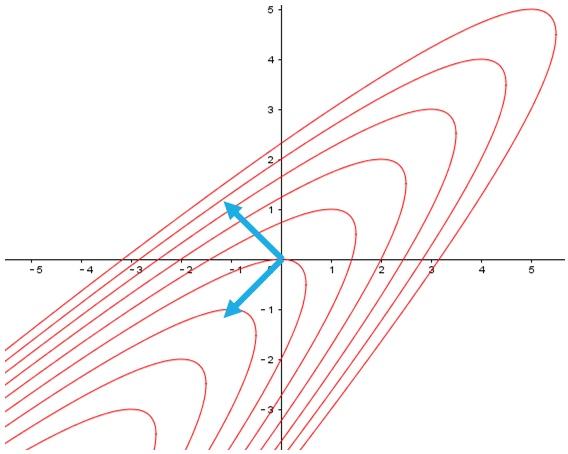

图 11

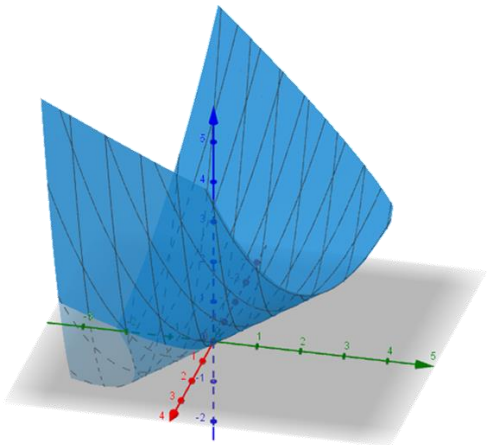

图 12

（四）Hessian 矩阵的特征值一负一零时（Hessian 矩阵半负定）

当 Hessian 矩阵的特征值一负一零时，由线性代数知识可知此时 Hessian 矩阵半负定，由上面两部分分析可知，此时要么没有极值点，要么有无数个共线的极值点。

【例七】（$\nabla f(\boldsymbol{x})=\mathbf{0}$ 欠定时） $f(\boldsymbol{x})=-\frac{1}{2}x_1^2+x_1x_2-\frac{1}{2}x_2^2=\frac{1}{2}\boldsymbol{x}^T\begin{bmatrix}-1 & 1\\ 1 & -1\end{bmatrix}\boldsymbol{x}$.

Hessian 矩阵以及它的特征值、特征向量为：

$$\nabla^2 f(\boldsymbol{x})=\begin{bmatrix}-1 & 1\\ 1 & -1\end{bmatrix},\quad \lambda_1=-2,\quad \boldsymbol{z}_1=\begin{bmatrix}-1\\ 1\end{bmatrix},\quad \lambda_2=0,\quad \boldsymbol{z}_2=\begin{bmatrix}-1\\ -1\end{bmatrix}$$

在这种情况下，第二个特征值是 0，也就是说在 $\boldsymbol{z}_2$ 方向上曲率为 0，由第三部分的分析可知，所有的极值点（此时也是最小值点）在一条直线上。该函数的等高线是一系列平行直线，函数曲面形状是一个倒驻点凹槽（倒平稳谷）（如下图 13、图 14 所示）。

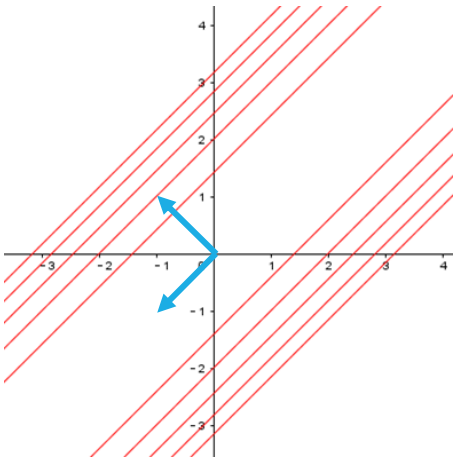

图 13

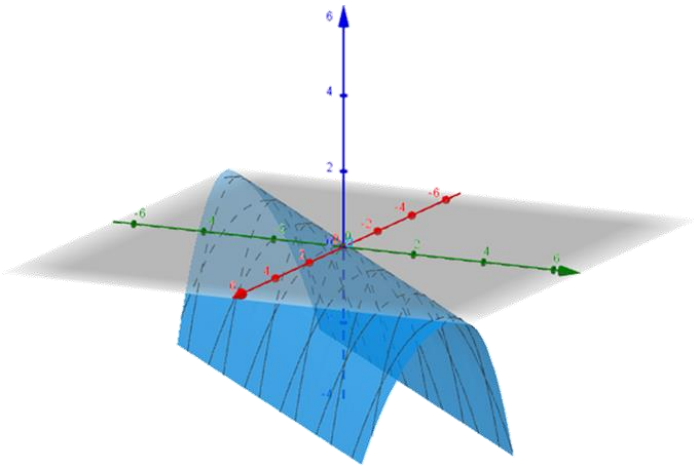

图 14

【例八】（$\nabla f(\boldsymbol{x})=\mathbf{0}$ 出现矛盾方程无解时）

$$f(\boldsymbol{x})=-\frac{1}{2}x_1^2+x_1x_2-\frac{1}{2}x_2^2+x_2=\frac{1}{2}\boldsymbol{x}^T\begin{bmatrix}-1 & 1\\ 1 & -1\end{bmatrix}\boldsymbol{x}+\begin{bmatrix}0\\1\end{bmatrix}^T\boldsymbol{x}.$$

Hessian 矩阵以及它的特征值、特征向量为：

$$\nabla^2 f(\boldsymbol{x})=\begin{bmatrix}-1 & 1\\ 1 & -1\end{bmatrix},\quad \lambda_1=-2,\quad \boldsymbol{z}_1=\begin{bmatrix}-1\\1\end{bmatrix},\quad \lambda_2=0,\quad \boldsymbol{z}_2=\begin{bmatrix}-1\\-1\end{bmatrix}$$

在这种情况下，令 $\nabla f(\boldsymbol{x})=\mathbf{0}$，则对应方程组 $\begin{cases}-x+y=0\\ x-y=-1\end{cases}$，两式矛盾，无解，亦即不存在驻点。该函数的等高线是一系列芽形线，函数曲面形状是一个山脊（倾斜倒凹槽）（如下图 15、图 16 所示）。

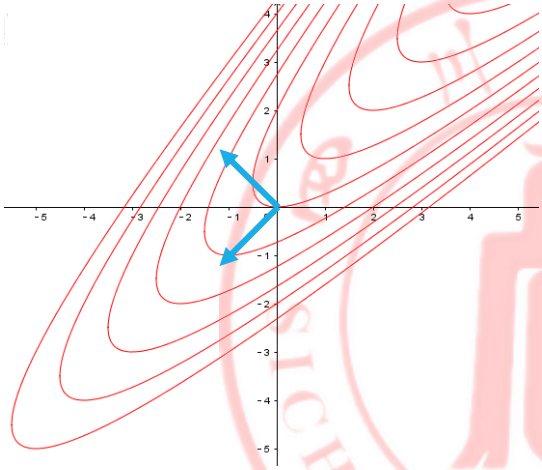

图 15

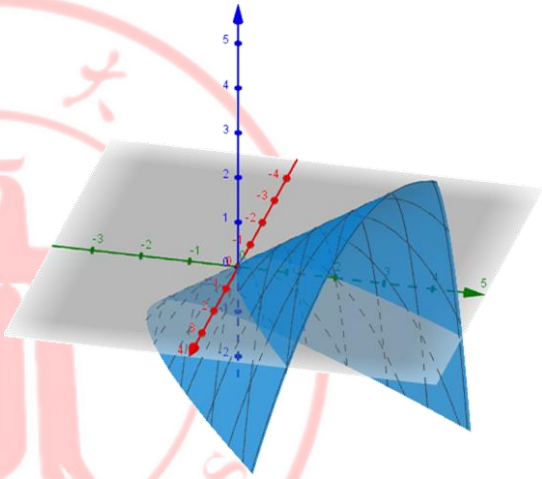

图 16

（五）Hessian 矩阵的特征值一正一负（异号）时

【例九】 $f(\boldsymbol{x})=-\frac{1}{4}x_1^2-\frac{3}{2}x_1x_2-\frac{1}{4}x_2^2=\frac{1}{2}\boldsymbol{x}^T\begin{bmatrix}-0.5 & -1.5\\ -1.5 & -0.5\end{bmatrix}\boldsymbol{x}$.

Hessian 矩阵以及它的特征值、特征向量为：

$$\nabla^2 f(\boldsymbol{x})=\begin{bmatrix}-0.5 & -1.5\\ -1.5 & -0.5\end{bmatrix},\quad \lambda_1=1,\quad \boldsymbol{z}_1=\begin{bmatrix}-1\\1\end{bmatrix},\quad \lambda_2=-2,\quad \boldsymbol{z}_2=\begin{bmatrix}-1\\-1\end{bmatrix}$$

在这种情况下，第一个特征值为正，因此在 $\boldsymbol{z}_1$ 方向曲率为正，函数呈上升趋势；第二个特征值为负，因此在 $\boldsymbol{z}_2$ 方向曲率为负，函数呈下降趋势。此时驻点不是极值点，而是一个鞍点。同时，在绝对值意义下，第二个特征值大于第一个特征值，所以 $\boldsymbol{z}_2$ 方向上的等高线更加稠密。该函数的等高线呈 X 形，函数曲面形状是一个拉伸的鞍面（如下图 17、图 18 所示）。

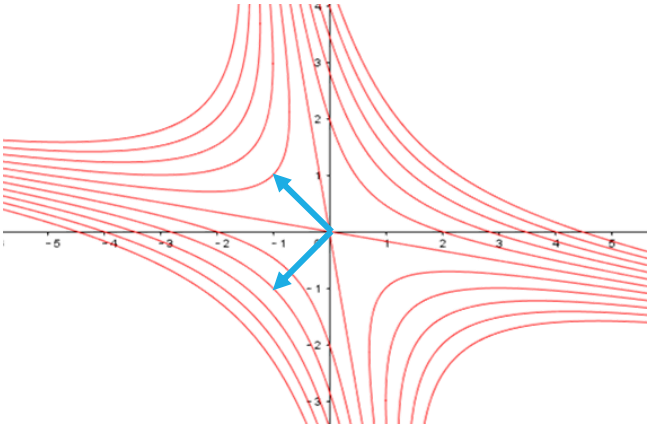

图 17

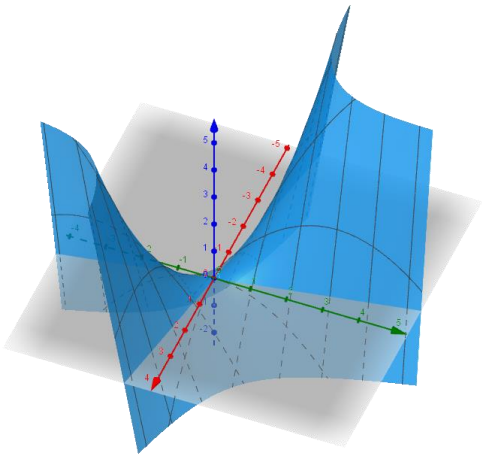

图 18

五、结论汇总

（一）Hessian 矩阵特征值、特征向量与函数图像关系

多元二次函数的 Hessian 矩阵的特征向量定义了一个新的二次交叉项衰减的坐标系。特征向量被称为函数等高线的主轴。在每一特征向量方向上，二阶导数都等于相应的特征值，若特征向量对应的特征值绝对值越大，则说明该方向上函数曲率越大，等高线越密集；相反，若特征向量对应的特征值绝对值越小，则说明该方向上函数曲率越小，等高线越稀疏。二阶导数的最大值存在于最大特征值所对应的特征向量的方向上，在其他方向上，二阶导数是特征值的加权平均。

由此即可判断函数图像形状。

（二）Hessian 矩阵与二次函数极值

当二次函数 $f(\boldsymbol{x})=\frac{1}{2}\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}+\boldsymbol{d}^T\boldsymbol{x}+c$ 有驻点 $\boldsymbol{x}^*$ 时，则有以下关系：

驻点 $\boldsymbol{x}^*$ 是强极小点，当且仅当 $\boldsymbol{A}$ 是正定矩阵；

驻点 $\boldsymbol{x}^*$ 是弱极小点，当且仅当 $\boldsymbol{A}$ 是半正定矩阵；

驻点 $\boldsymbol{x}^*$ 是强极大点，当且仅当 $\boldsymbol{A}$ 是负定矩阵；

驻点 $\boldsymbol{x}^*$ 是弱极大点，当且仅当 $\boldsymbol{A}$ 是半负定矩阵。

当 $\boldsymbol{A}$ 是正定矩阵或负定矩阵时，存在唯一极小（大）值点 $\boldsymbol{x}^*=-\boldsymbol{A}^{-1}\boldsymbol{d}$，同时也是最小（大）值点；

当 $\boldsymbol{A}$ 是半正定矩阵或半负定矩阵时，要么没有极值点（对应方程组 $\nabla f(\boldsymbol{x})=\boldsymbol{0}$ 出现矛盾方程），要么有无数个极值点（对应方程组 $\nabla f(\boldsymbol{x})=\boldsymbol{0}$ 欠定），且它们都是最值点。

如果 Hessian 矩阵的所有特征值都为正，则函数存在一个唯一的强极小点 $\boldsymbol{x}^* = -\boldsymbol{A}^{-1}\boldsymbol{d}$；

如果 Hessian 矩阵的所有特征值都为负，则函数存在一个唯一的强极大点 $\boldsymbol{x}^* = -\boldsymbol{A}^{-1}\boldsymbol{d}$；

如果 Hessian 矩阵的特征值有正有负，则函数存在一个唯一的鞍点 $\boldsymbol{x}^* = -\boldsymbol{A}^{-1}\boldsymbol{d}$；

如果 Hessian 矩阵的所有特征值都非负，但某些特征值为 0，则函数存在弱极小点，或没有驻点；

如果 Hessian 矩阵的所有特征值都非正，但某些特征值为 0，则函数存在弱极大点，或没有驻点。

（三）多元二次函数图像分类——以二元二次函数为例

此处只列出简要结论，具体分析见第四部分。

（1）Hessian 矩阵的特征值都为正时（Hessian 矩阵正定）

① 特征值相等时

函数的等高线是一系列同心圆，函数曲面形状是一个圆形空洞；

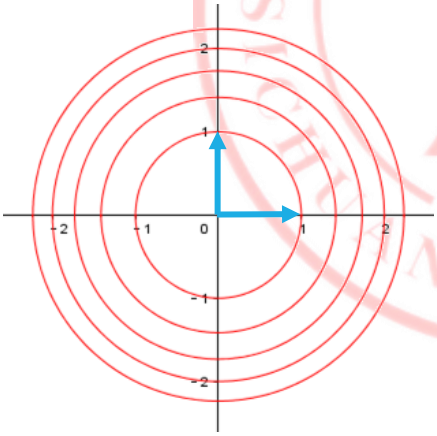

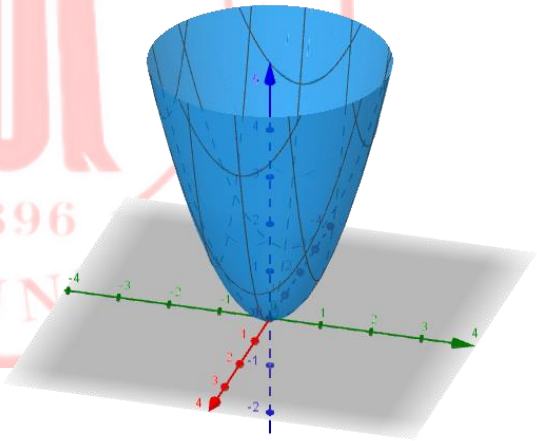

② 特征值不相等时.

函数的等高线是一系列同中心椭圆，函数曲面形状是一个椭圆空洞；

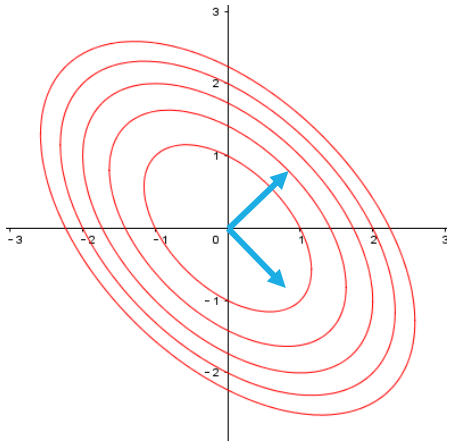

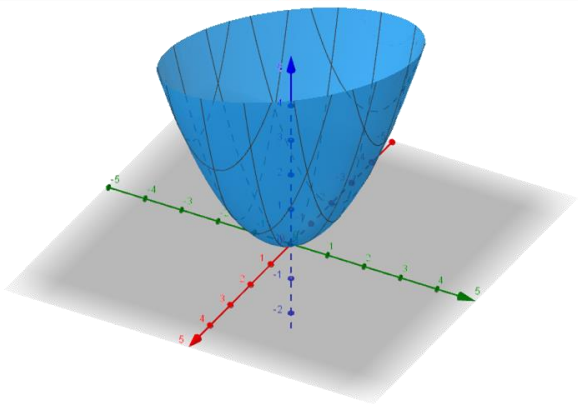

（2）Hessian 矩阵的特征值都为负时（Hessian 矩阵负定）

① 特征值相等时

函数的等高线是一系列同心圆，函数曲面形状是一个倒圆形空洞；

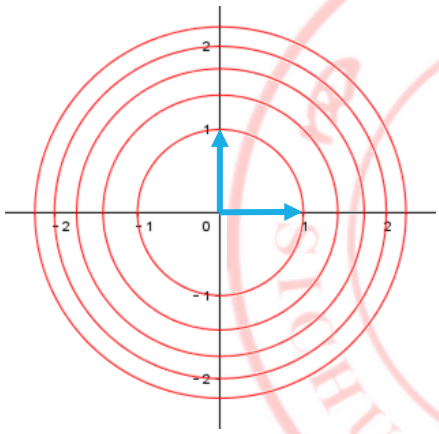

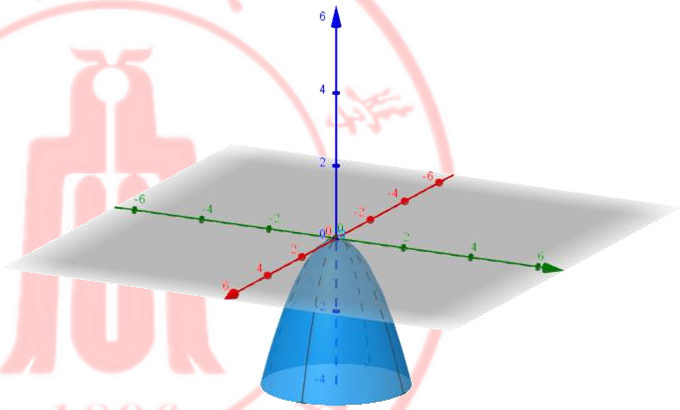

② 特征值不相等时

函数的等高线是一系列同中心椭圆，函数曲面形状是一个倒椭圆空洞；

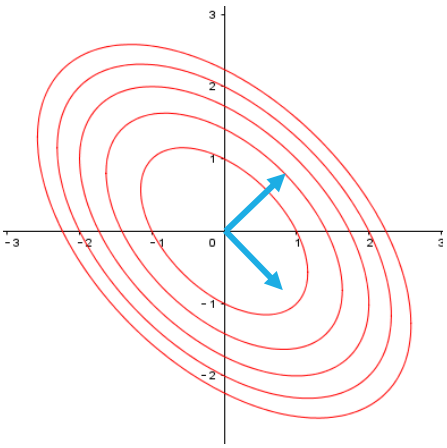

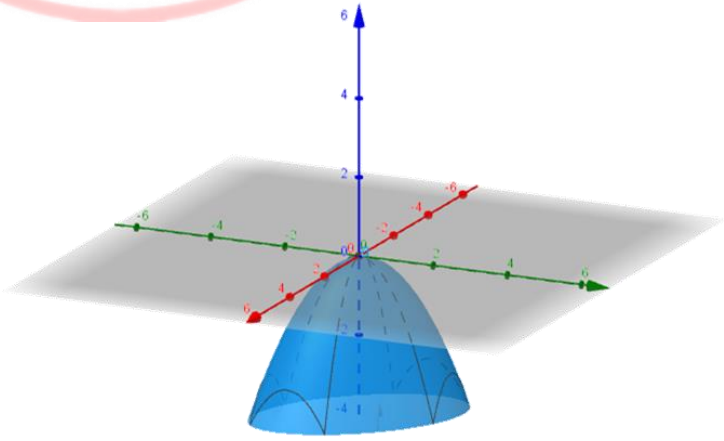

（3）Hessian 矩阵的特征值一正一零时（Hessian 矩阵半正定）

① $\nabla f(\boldsymbol{x})=\mathbf{0}$ 欠定时

函数的等高线是一系列平行直线，函数曲面形状是一个驻点凹槽（平稳谷）；

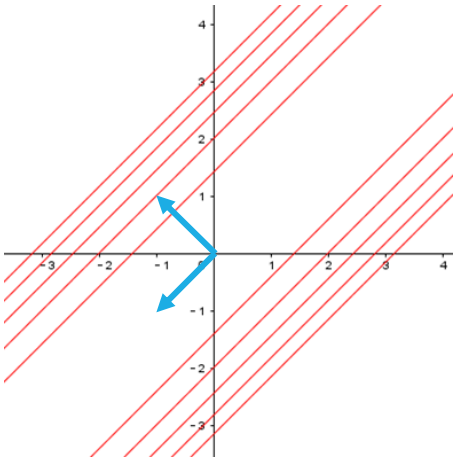

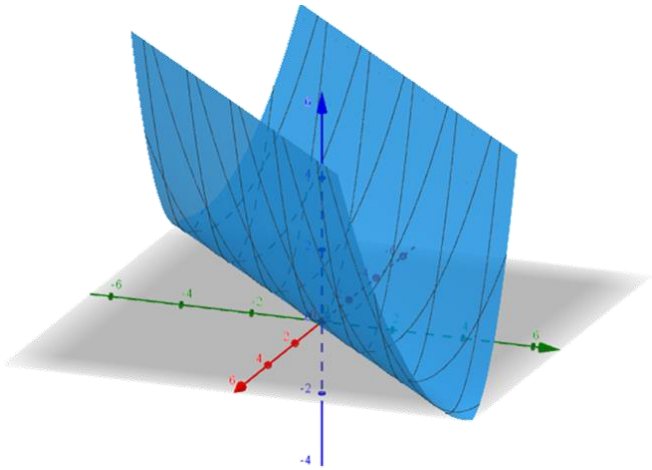

② $\nabla f(\boldsymbol{x})=\mathbf{0}$ 出现矛盾方程无解时

函数的等高线是一系列芽形线，函数曲面形状是一个山谷（倾斜凹槽）；

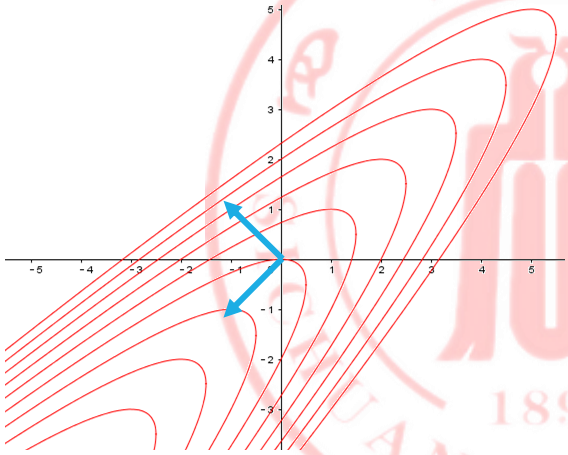

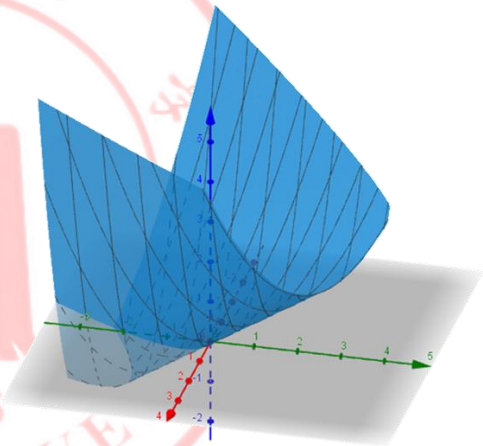

（4）Hessian 矩阵的特征值一负一零时（Hessian 矩阵半负定）

① $\nabla f(\boldsymbol{x})=\mathbf{0}$ 欠定时

函数的等高线是一系列平行直线，函数曲面形状是一个倒驻点凹槽（倒平稳谷）；

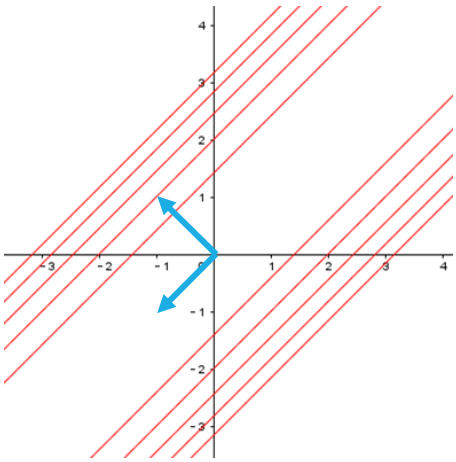

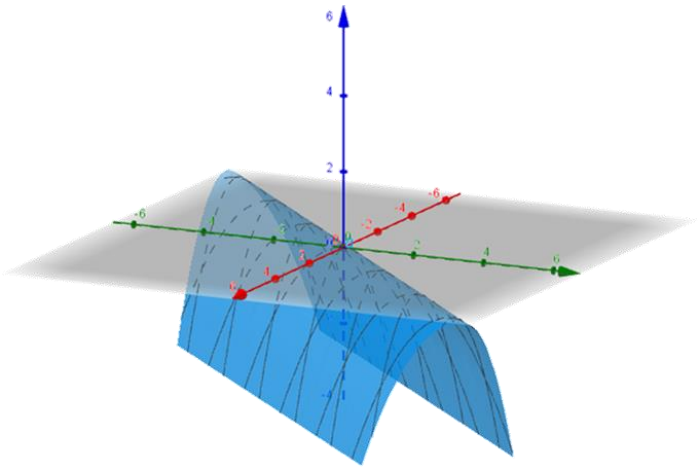

② $\nabla f(\boldsymbol{x})=\mathbf{0}$ 出现矛盾方程无解时

函数的等高线是一系列芽形线，函数曲面形状是一个山脊（倾斜倒凹槽）；

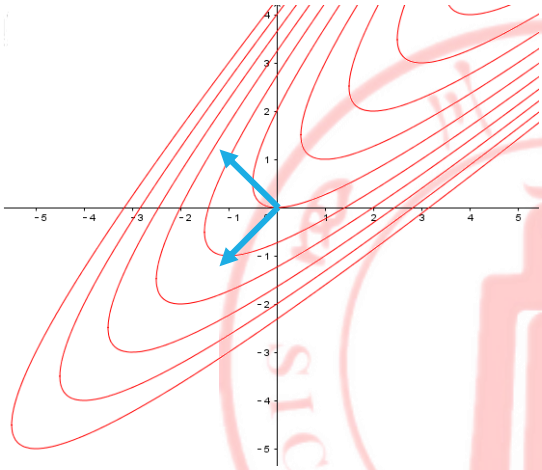

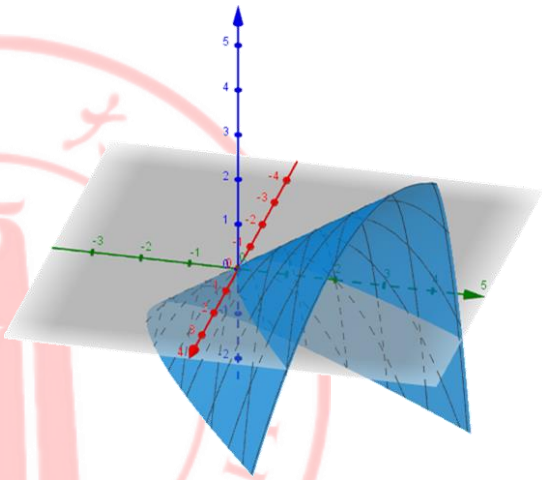

（5）**Hessian 矩阵的特征值一正一负（异号）时**

函数的等高线呈 X 形，函数曲面形状是一个拉伸的鞍面。

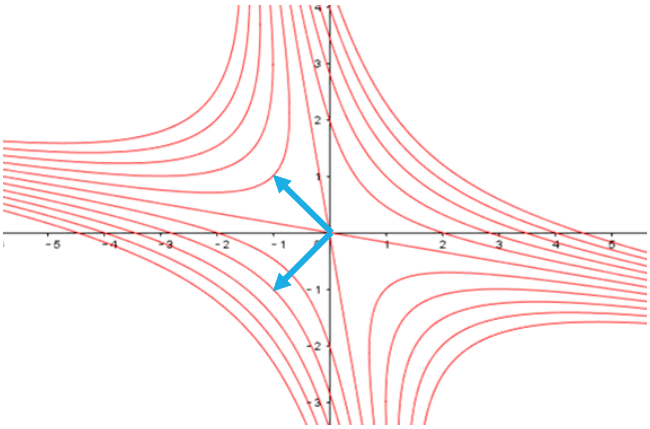

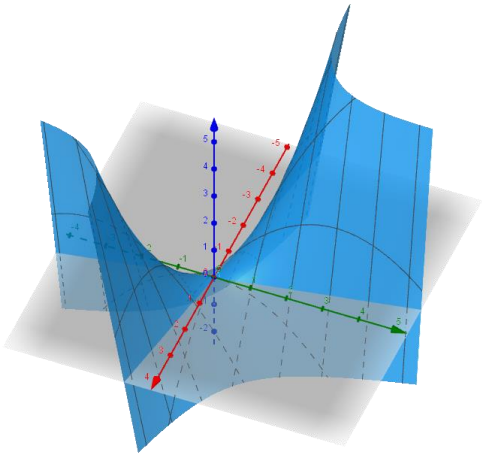

参考文献

[1] Boyd S, Boyd S P, Vandenberghe L. Convex optimization[M]. Cambridge university press, 2004.

[2] Zhang X. Matrix analysis and applications[M]. Cambridge University Press, 2017.

[3] Petersen K B, Pedersen M S. The matrix cookbook (version: November 15, 2012)[J]. 2012.

[4] Hagan M T, Demuth H B, Beale M. Neural network design[M]. PWS Publishing Co., 1997.

[5] Zou Y. Multi-Variable Calculus: A First Step[M]. Walter de Gruyter GmbH & Co KG, 2020.

[6] Lay D C, Lay S R, McDonald J J. Linear algebra and its applications[M]. Pearson, 2016.